
RUST CHINA CONF 2023

第三届中国Rust开发者大会



6.17-6.18 @Shanghai

使用Rust与ClickHouse构建高 效可靠的日志系统

刘炜 腾讯云(专有云)

大纲

- 自我介绍 系统介绍 整体架构 系统实现 遇到问题



自我介绍

自我介绍

- 大龄码农
- · 做过嵌入式/CDN/数据库开发
- 从C/C++到Rust
- 现在在腾讯云(专有云)从事日志系统的开发



- 属于腾讯专有云PaaS平台(TCS)
- 承接TCS底座日志
- 从Loki=>Menicus
- 提供日志的搜索/报警/处理等功能

- 为什么放弃 Loki
 - 资源占用过大
 - 统计/计算能力比较弱
 - 组件过多, 排查问题比较困难
 - 商业使用不友好的开源协议
- 为什么选择Mencius+ClickHouse
 - 存储计算与业务分离
 - 计算/统计能力更强
 - 资源占用更小,性能更好
 - 更友好的开源协议

- 多种接入方式
 - Agent
 - Client
- 查询
 - LogQL
 - OpenTSDB
- 其他功能
 - 多租户
 - 自定义索引
 - 多维度统计
 - 鉴权
 - ...

- 写入
 - 每天 100G
- 磁盘
 - 压缩比 1:13
- 内存
 - Mencius
 - 200M左右
 - ClickHouse
 - 2G以下


```
SELECT
   partition,
formatReadableSize(sum(bytes_on_disk)),
sum(data_uncompressed_bytes) / sum(data_compressed_bytes)
FROM system.parts
WHERE partition >= '20220806'
GROUP BY partition
Ouerv id: cee8d8d0-91fb-4f08-b393-ac93b192463f
  -partition---formatReadableSize(sum(bytes_on_disk))---divide(sum(data_uncompressed_bytes), sum(data_compressed_bytes))-
   20220806
               13.13 GiB
                                                                                                                   13.50751067635851
   20220808
               4.33 GiB
                                                                                                                   14.53635756025943
               3.38 MiB
                                                                                                                   6.923569579029528
   tuple()
4 rows in set. Elapsed: 0.520 sec. Processed 1.65 thousand rows, 69.90 KB (3.17 thousand rows/s., 134.37 KB/s.)
```






整体架构

- 接入端
- API Gateway
- 日志服务(Mencius)
- 存储(ClickHouse)




系统实现

- 协议层
- 处理层
- 计算层
- 存储层



协议层

- 支持协议
 - Loki
 - 写入
 - Json/ProtoBuf
 - 查询
 - LogQL
 - Log Queries
 - Metric Queries
 - OpenTSDB
 - 统计/计算




协议层

- Parser
 - 手写
 - 为什么?
 - LogQL=>Token=>AST=>SQL
 - 测试
 - Fuzz testing


```
{app="foo"} \models "bar" | logfmt| latency \geq 250ms or ( status_code < 500 and status_code > 200)

Tokeninzer
```

[OpenBrace, Identifier(Word { value: "app", keyword: None }), EQ, String("foo"), CloseBrace, Whitespace(Space), PipeExact, Whitespace(Space),
Whitespace(Space), Gt, Whitespace(Space), Number(Number("200")), CloseParenthesis]




处理层



- Processor
 - 初始化
 - 静态/动态
 - 执行
 - 读/写
 - 结构
 - prediccate
 - process(&self, streams: Streams) -> Streams
 - 类型
 - 修改原始数据
 - 抽取原始数据字段
 - Json/LogFmt

计算层

- 大部分计算交给ClickHouse
 - Aggregation operators
- Vector 的计算
 - 报警使用
 - Binary operator
 - >, == ...
 - Vector matching
 - 匹配两个Vector



存储层

- WAL
 - 移植LevelDB的 WAL
 - 定长的 Block
 - Batch 写入 ClickHouse
- Flush Worker
 - 异步任务定时刷新 WAL
 - 清理策略
- Schema同步
 - 转换SQL

存储层

- ClickHouse
 - 使用Array来保存 Labels
 - 物化列
 - Lowcardinality(String)
 - 加速查询
 - Skipping Indexes
 - 日志全文索引

```
"streams":
       "stream": { "name": "bar2"},
       "values": [
                           "1570818238000000000", "fizzbuzz" ] ,
                         [ "1570818238000000000", "fizzbuzz" ]
Create table logs {
module String,
name Lowcardinality(String) MATERIALIZED labels_string_value[indexOf(labels_string_name, 'name')] ,
lables_string_name Array(String),
labels_string_value Array(String),
// log line
line String,
index_line line TYPE ngrambf_v1(10, 256, 2, 0),
```

问题

- Rust
 - Lifetime侵入性比较强
 - 库质量参差不齐
- ClickHouse
 - 可运维性弱
 - 强Schema带来不够灵活的缺点
 - 全文索引支持比较弱

Thank you!

